

Filipy Tavares dos Santos,
Luiz Otavio Machado Seles,
Naum Calebe Felix Sarti

Análise de Mercado de Jogos Eletrônicos com Base na Loja Virtual Steam

Rio Claro - SP

2026

Filipy Tavares dos Santos,
Luiz Otavio Machado Seles,
Naum Calebe Felix Sarti

Análise de Mercado de Jogos Eletrônicos com Base na Loja Virtual Steam

Relatório acadêmico apresentado como requisito parcial para aprovação na disciplina 'Mineração de Dados' do Curso de Graduação da Fatec.

Fatec - Rio Claro
Inteligência Artificial

Rio Claro - SP
2026

Sumário

1	INTRODUÇÃO	3
1.1	Descrição do Problema	3
1.2	Objetivo	3
1.3	Proposta do Trabalho	3
2	JUSTIFICATIVA	5
3	REVISÃO DA LITERATURA	6
4	METODOLOGIA	7
4.1	Base de Dados	7
4.1.1	Volume e Estrutura dos Dados	7
4.2	Agrupamento	8
4.2.1	Objetivo da Análise	8
4.2.2	Dados Utilizados e Significado Analítico	8
4.2.3	Pré-processamento	9
4.2.4	Escolha do Algoritmo	10
4.2.5	Definição do Número de Grupos (k)	11
4.2.6	Resultados	13
4.2.6.1	Gráfico de Dispersão (Scatter Plot)	13
4.2.6.2	Perfil dos Clusters	14
4.3	Regras de associação	16
4.3.1	Objetivo da análise	16
4.3.2	Dados Utilizados	16
4.3.3	Pré-processamento	17
4.3.4	Algoritmo Utilizado	18
4.3.5	Resultados	19
	CONCLUSÃO	23
	REFERÊNCIAS	25

1 Introdução

1.1 Descrição do Problema

O mercado global de jogos digitais, tendo a plataforma Steam como principal vitrine para PC, caracteriza-se por um volume massivo de lançamentos anuais, ultrapassando os 19.000 novos títulos em 2025 ([Video Game Insights, 2025](#)). Esta saturação impõe um desafio crítico para desenvolvedores e editores: a dificuldade em prever quais variáveis — como preço, gêneros, recepção crítica e engajamento social — determinam o sucesso comercial e a longevidade de um produto ([MARCHAND; HENNIG-THURAU, 2013](#); [LIN et al., 2019](#)). A complexidade e a alta dimensionalidade desses dados tornam análises empíricas tradicionais insuficientes, exigindo a aplicação de abordagens computacionais rigorosas, como mineração de dados e aprendizado de máquina, para identificar padrões de performance e mitigar riscos de investimento ([SIFA; BAUCKHAGE; DRACHEN, 2015](#); [ZUO; YIN et al., 2021](#)).

1.2 Objetivo

Este trabalho tem como objetivo identificar padrões estruturais de mercado na Steam através de técnicas de aprendizagem não supervisionada. Pretende-se segmentar os jogos em grupos (clusters) que compartilhem perfis de desempenho similares, permitindo extrair *insights* estratégicos sobre o comportamento dos jogadores e as dinâmicas de monetização que sustentam a indústria atual ([DemandSage, 2026](#)).

1.3 Proposta do Trabalho

A metodologia proposta baseia-se na aplicação de algoritmos de agrupamento, nomeadamente *K-Means*, sobre um conjunto de dados processado e normalizado. O fluxo de trabalho compreende:

- **Tratamento de Dados:** Limpeza, normalização de variáveis (ex: *peak_ccu*, receitas estimadas, preço) e tratamento de assimetria.
- **Modelagem:** Determinação do número ideal de clusters através do Método do Cotovelo e do Coeficiente de Silhueta.

- **Análise de Perfil:** Interpretação dos resultados para caracterizar cada segmento de mercado, provendo inteligência estratégica para a tomada de decisão em lançamentos de novos títulos.

2 Justificativa

Este estudo é justificado pelo grande crescimento do mercado mundial de jogos e pela necessidade de entender como esse comércio funciona para guiar a criação e a venda de novos produtos. A importância da pesquisa está no peso financeiro desse setor de entretenimento e na dificuldade de enfrentar um mercado tão competitivo, onde usar dados é fundamental para que os negócios sobrevivam.

A indústria de jogos eletrônicos se tornou um dos setores que mais gera dinheiro no mundo. O mercado global de jogos faturou cerca de 360,4 bilhões de dólares em 2025 ([Fortune Business Insights, 2025](#)). Esse valor é alcançado graças a um público de aproximadamente 3,49 bilhões de jogadores ativos no planeta ([Quantumrun Foresight, 2026](#)). O setor de computadores (PC) continua forte e em crescimento, com uma previsão de faturamento de 39,9 bilhões de dólares em programas e jogos no mesmo ano ([Quantumrun Foresight, 2026](#)).

Com esse crescimento, as vendas pela internet viraram o principal canal de comércio, e a Steam se destaca como a maior e mais importante loja de jogos para PC do mundo. A plataforma domina cerca de 75% do mercado de vendas digitais de jogos para PC nos Estados Unidos ([DemandSage, 2026](#)). O tamanho da plataforma fica claro em seus resultados financeiros, já que ela alcançou faturamentos recordes na faixa de 10,8 bilhões de dólares por ano ([DemandSage, 2026](#)). Além disso, a Steam mantém 132 milhões de usuários ativos por mês e atingiu um recorde de 41,8 milhões de pessoas conectadas ao mesmo tempo em janeiro de 2026 ([DemandSage, 2026](#)).

Com o grande volume de lançamentos — que atingiu a marca recorde de 19.994 títulos publicados na Steam apenas em 2025 ([DemandSage, 2026](#)) —, o mercado tornou-se bastante saturado. Para que os desenvolvedores consigam se destacar diante de tanta concorrência, é fundamental entender o comportamento do consumidor, a viabilidade financeira, os preços cobrados e o que o público realmente prefere.

Dessa forma, analisar os dados da Steam é importante porque fornece informações estratégicas claras. Ao encontrar os padrões que levam ao sucesso comercial na maior loja virtual de jogos do mundo, o estudo entrega dados concretos para apoiar as decisões de negócio. Isso diminui a necessidade de agir apenas por intuição e ajuda os produtores a reduzirem os riscos financeiros ao lançar novos títulos digitais.

3 Revisão da Literatura

A análise do mercado de jogos digitais na plataforma Steam baseia-se fortemente na interpretação de dados públicos de desempenho, um campo enriquecido por analistas independentes que disponibilizam os seus estudos abertamente na internet. A relevância destas análises reside na capacidade de transformar métricas abertas — como a quantidade de avaliações (*reviews*) e o comportamento de algoritmos de recomendação — em inteligência competitiva e estratégica para o desenvolvimento de jogos.

Um dos pilares conceituais da análise moderna da Steam é o estudo da "descoberta" (*discoverability*) e a segmentação de desempenho de mercado. De acordo com as análises quantitativas publicadas no portal de dados abertos *GameDiscoverCo* (CARLESS, 2024), o sucesso comercial na plataforma segue uma distribuição de cauda longa altamente acentuada. Os relatórios públicos demonstram que o volume de adições à lista de desejos (*wishlists*) no período de pré-lançamento atua como o principal preditor do volume de vendas na semana de estreia, permitindo agrupar os jogos em diferentes faixas de expectativa de receita antes mesmo de chegarem ao mercado.

Complementarmente, os estudos empíricos conduzidos no portal *How To Market A Game* (ZUKOWSKI, 2025) aprofundam a relação entre o preço de tela, o gênero do jogo e o seu potencial de retenção. Através da análise de dados históricos públicos, as pesquisas indicam que determinados gêneros (como estratégia, simuladores e *roguelikes*) possuem comunidades muito mais resilientes e propensas a consumir jogos independentes. Além disso, o portal documenta variações críticas no chamado "multiplicador de Boxleiter"— a métrica modificada que estima o número de vendas reais com base no número de avaliações visíveis —, provando que diferentes categorias de jogos respondem de formas totalmente distintas ao mercado. Esses achados validam a aplicação de técnicas de agrupamento (*clustering*) para segmentar o mercado não apenas por afinidade temática, mas pelo comportamento financeiro e dinâmicas de engajamento da audiência.

4 Metodologia

4.1 Base de Dados

O presente estudo utiliza uma base de dados real obtida publicamente na plataforma Kaggle, intitulada "*Steam Games Dataset 2025*". O arquivo específico utilizado corresponde à versão processada e refinada denominada `games_march2025_cleaned.csv` (Artermiloff, 2025). Os dados originais foram extraídos diretamente da API pública da Steam (*Steam Web API*) e complementados com métricas de estimativa de vendas provenientes do ecossistema *SteamSpy*.

A base de dados limpa e tratada contém o registro de milhares de jogos publicados na plataforma até o primeiro trimestre de 2025. Cada linha do conjunto de dados representa um jogo único, mapeado por uma ampla gama de colunas que combinam metadados textuais, técnicos e comerciais. Entre as variáveis disponíveis, destacam-se informações de identificação e catálogo (como nome, data de lançamento, desenvolvedores e distribuidores), características técnicas de acessibilidade (como idiomas suportados e compatibilidade com o sistema Linux), além de marcadores qualitativos formados por categorias, gêneros e etiquetas (*tags*) atribuídas pela comunidade. Complementarmente, o *dataset* concentra métricas numéricas de engajamento e recepção pública, incluindo o tempo médio de jogo (*playtime*), volume de avaliações recentes e históricas, além de dados consolidados de receita estimada e picos de acessos simultâneos, essenciais para caracterizar o perfil comercial de cada título.

4.1.1 Volume e Estrutura dos Dados

Na sua forma original, a base de dados abrigava um total de 89.618 registos únicos (jogos) e 47 atributos descritivos, englobando metadados de catálogo, métricas de engajamento e avaliações financeiras.

Para adequar o conjunto de dados aos objetivos da análise, realizou-se uma filtragem que descartou colunas com elevada escassez de informação (mais de 50% de valores ausentes), seguida de uma seleção de colunas relevantes ao estudo de mercado, resultando num subconjunto focado de 22 colunas essenciais.

Nesta etapa, aplicou-se também um tratamento estrutural na variável `estimated_owners`. Originalmente fornecida em formato textual de intervalos (por exemplo, "1000 - 2000"), esta coluna foi processada por uma função de limpeza que removeu caracteres não numéricos e calculou a média aritmética das balizas de cada intervalo, convertendo o atributo

numa variável numérica contínua.

Após esta conversão, aplicou-se no subconjunto uma série de critérios de significância de mercado — tais como $\text{num_reviews_total} \geq 30$, $\text{estimated_owners} \geq 100$ e $\text{peak_ccu} \geq 1$ —, o que permitiu excluir títulos sem tração comercial real. Ao final, o conjunto validado e utilizado para processamento resultou em 15.550 registros estruturados, contendo as 22 colunas selecionadas.

4.2 Agrupamento

4.2.1 Objetivo da Análise

O objetivo central da aplicação de algoritmos não supervisionados de agrupamento (*clustering*) a este conjunto de dados é realizar uma segmentação comportamental e comercial do mercado de videogames na plataforma Steam. Num ecossistema altamente saturado e de cauda longa, o agrupamento permite descobrir como os títulos se organizam naturalmente em diferentes perfis ou nichos (por exemplo: sucessos globais/*blockbusters*, jogos de nicho altamente aclamados, ou títulos de alto custo com baixa adoção) sem depender de rótulos comerciais pré-definidos.

Através desta técnica, procura-se identificar padrões latentes de consumo, respondendo a questões estratégicas como: *"Quais são as características que separam os grandes sucessos dos títulos medianos?"* e *"Como o preço e a qualidade percebida influenciam a adoção e o engajamento da comunidade?"*.

4.2.2 Dados Utilizados e Significado Analítico

Para materializar este objetivo, a análise foca-se no subconjunto processado de 15.550 jogos válidos (`df_processed`), utilizando um vetor específico de cinco atributos numéricos contínuos. A seleção destas cinco colunas não foi arbitrária; em conjunto, elas formam uma matriz multidimensional que descreve o "ciclo de vida e sucesso" de cada jogo no mercado:

- **Penetração de Mercado (`estimated_owners`):** Representa o tamanho da base instalada de jogadores. Reflete o alcance comercial absoluto e a capacidade do jogo de gerar vendas.
- **Intensidade de Engajamento (`peak_ccu`):** O pico de jogadores simultâneos mede o impacto do título no seu momento de maior tração (o *hype*). Um jogo pode ter muitos proprietários, mas apenas jogos com forte retenção ou lançamentos virais geram picos massivos de utilizadores simultâneos.

- **Visibilidade e Interação (`num_reviews_total`):** Funciona como um *proxy* altamente fiável para o nível de atividade da comunidade. Um elevado número de avaliações demonstra que o jogo não apenas foi comprado, mas gerou interação suficiente para motivar o jogador a deixar uma opinião.
- **Sentimento do Consumidor (`pct_pos_total`):** Captura a qualidade percebida do produto. Diferencia, por exemplo, um jogo muito popular e aclamado de um jogo que recebeu muita atenção devido a polémicas ou falhas técnicas (*review bombing*).
- **Posicionamento Financeiro (`price`):** Define a barreira de entrada e a categoria económica do jogo (desde títulos gratuitos/baratos de produção independente até lançamentos *Premium/AAA*).

A sinergia destas cinco variáveis dota o algoritmo de todas as dimensões essenciais para agrupar os dados de forma lógica. Ao analisar o volume de adoção (*owners* e *reviews*), a intensidade (*peak_ccu*), a receção (*pct_pos*) e o custo financeiro (*price*), o modelo matemático ganha a capacidade de mapear o mercado na sua totalidade, separando de forma orgânica os diferentes perfis de sucesso na plataforma Steam.

4.2.3 Pré-processamento

Para a aplicação das técnicas de agrupamento espacial, foi construída a matriz de características denominada `X_grouping`, derivada do subconjunto de dados previamente validado (`df_processed`). A seleção de variáveis focou estritamente em cinco indicadores numéricos que representam o desempenho comercial e o engajamento dos jogos: `peak_ccu`, `pct_pos_total`, `num_reviews_total`, `estimated_owners` e `price`.

O preparo desta matriz exigiu transformações matemáticas essenciais para adequar os dados aos algoritmos baseados em cálculo de distância geométrica, sendo dividido nas seguintes etapas:

1. **Transformação Logarítmica:** Devido à natureza do mercado de videojogos, que exhibe uma distribuição de cauda longa extrema (onde poucos jogos concentram a maioria dos acessos e vendas), variáveis de volume tendem a possuir alta assimetria e *outliers* severos. Para estabilizar a variância, aplicou-se a transformação matemática $f(x) = \ln(x + 1)$ (função `log1p`) especificamente nas colunas de `peak_ccu`, `num_reviews_total` e `estimated_owners`. As variáveis `price` e `pct_pos_total` não sofreram essa transformação por já possuírem limites e escalas comportadas.
2. **Padronização de Escala (Z-score):** Como os algoritmos de *clustering* calculam distâncias (ex: distância Euclidiana) entre os pontos de dados, atributos com valores absolutos maiores poderiam dominar o processo de agrupamento. Para evitar esse

viés, aplicou-se o método `StandardScaler` a todas as cinco variáveis do `X_grouping`. Este procedimento escalona os dados para que cada atributo apresente média igual a zero ($\mu = 0$) e desvio padrão igual a um ($\sigma = 1$).

Tabela 1 – Atributos selecionados para a matriz de agrupamento (`X_grouping`) e respectivas transformações de pré-processamento.

Atributo	Transformação	Descrição
<code>peak_ccu</code>	$\ln(x + 1) + \text{Z-score}$	Pico histórico de jogadores simultâneos conectados ao título. Reflete o engajamento máximo da comunidade.
<code>num_reviews_total</code>	$\ln(x + 1) + \text{Z-score}$	Volume absoluto de avaliações submetidas. Atua como um <i>proxy</i> robusto para medir a visibilidade do jogo.
<code>estimated_owners</code>	$\ln(x + 1) + \text{Z-score}$	Estimativa contínua do número de cópias adquiridas, indicando a base instalada e a penetração de mercado.
<code>price</code>	Z-score	Preço base comercializado na plataforma (em dólares). Não exigiu transformação logarítmica.
<code>pct_pos_total</code>	Z-score	Porcentagem de avaliações globais classificadas como positivas, indicando a recepção e a qualidade percebida.

4.2.4 Escolha do Algoritmo

Para a segmentação de mercado na plataforma Steam, procedeu-se à avaliação comparativa de três técnicas não supervisionadas: *K-Means*, *K-Medoids* e Agrupamento Hierárquico. A seleção final recaiu sobre o algoritmo *K-Means*, fundamentada no equilíbrio ótimo entre viabilidade computacional e a interpretabilidade analítica dos resultados.

O *K-Means* destacou-se por apresentar um tempo de execução altamente eficiente e por convergir para *clusters* com forte coerência de mercado. Os perfis de jogos gerados por este modelo refletiram de forma clara e lógica as dinâmicas reais da plataforma, isolando corretamente as diferentes fatias de sucesso comercial e de engajamento sem distorcer os dados.

Em contrapartida, o *K-Medoids* foi descartado. Embora tenha alcançado resultados muito semelhantes nas métricas estatísticas de validação (tais como o Método do Cotovelo e o Coeficiente de Silhueta), o seu custo computacional revelou-se significativamente superior. Além disso, de forma crítica, o algoritmo tendeu a forçar uma distribuição excessivamente equilibrada e uniforme das instâncias entre os grupos. Num mercado caracterizado por uma extrema assimetria de "cauda longa"— onde uma vasta maioria de

jogos tem baixo alcance e uma minoria absoluta domina as vendas —, esta homogeneização forçada gerou *clusters* artificiais que careciam de sentido prático para a análise de negócio.

Por fim, o Agrupamento Hierárquico (*Hierarchical Clustering*) também foi preterido. Para além do tempo de execução ser proibitivo devido ao cálculo recursivo da matriz de distâncias para milhares de instâncias, o método divergiu substancialmente na sugestão do número ótimo de grupos. A topologia final gerada demonstrou baixa qualidade analítica, sendo incapaz de capturar os padrões latentes do ecossistema de forma satisfatória quando comparada à clareza do *K-Means*.

4.2.5 Definição do Número de Grupos (k)

A determinação do número ótimo de grupos (k) é uma etapa crítica na parametrização do algoritmo *K-Means*. Para garantir uma escolha matematicamente fundamentada, procedeu-se à avaliação conjunta de duas das métricas de validação interna mais consolidadas na literatura: o Método do Cotovelo (*Elbow Method*) e o Coeficiente de Silhueta (*Silhouette Score*).

A análise dos resultados revelou uma divergência clara entre as sugestões métricas. Conforme ilustrado pelos testes, o Coeficiente de Silhueta atingiu a sua pontuação máxima para $k = 2$, sugerindo uma divisão binária dos dados. Por outro lado, a curva de inércia (Soma dos Quadrados Intra-Cluster) gerada pelo Método do Cotovelo apresentou o seu ponto de inflexão (a zona de ganho marginal decrescente) estabelecendo-se ao redor de $k = 5$.

Perante esta divergência, a decisão final para a modelagem recaiu sobre $k = 5$, preterindo a sugestão de $k = 2$ por critérios de interpretabilidade e aplicabilidade de negócio.

Do ponto de vista analítico, embora $k = 2$ maximize a métrica de Silhueta, esta divisão traduz-se numa polarização extrema do conjunto de dados. Num ecossistema como o da Steam — fortemente pautado por uma distribuição de cauda longa —, uma segmentação em apenas dois grupos resultaria numa dicotomia simplista e sem valor prático, separando essencialmente a ínfima minoria de "jogos AAA de altíssimo sucesso" contra um bloco massivo contendo "todo o resto do mercado".

A adoção de $k = 5$, sustentada pelo Método do Cotovelo, permite uma estratificação muito mais granular e fiel à realidade da indústria. Com cinco *clusters*, o modelo adquire a sensibilidade necessária para mapear as ricas dinâmicas intermediárias da plataforma, isolando perfis distintos como títulos *indies* de entrada, sucessos de nicho, projetos medianos e os verdadeiros *blockbusters*. Desta forma, a parametrização em $k = 5$ garante o equilíbrio ideal entre a validade estatística e a extração de conhecimento acionável.




Figura 1 – Método do Cotovelo indicando a inflexão da inércia próxima a $k=5$.




Figura 2 – Análise do Coeficiente de Silhueta com pico em $k=2$.

4.2.6 Resultados

4.2.6.1 Gráfico de Dispersão (Scatter Plot)




Figura 3 – Dispersão dos agrupamentos no espaço vetorial gerado pelo algoritmo *K-Means* ($k = 5$) com redução de dimensionalidade via PCA.

Como a matriz de agrupamento (**X_grouping**) é composta por cinco dimensões (atributos), a sua visualização geométrica direta é inviável no espaço tridimensional perceptível pelo ser humano. Para contornar essa limitação sem perder a riqueza rica dos dados, utilizou-se a Análise de Componentes Principais (*Principal Component Analysis* — PCA).

O PCA é uma técnica de aprendizagem estatística não supervisionada que realiza uma transformação linear no espaço amostral. O seu objetivo é projetar um conjunto de dados de alta dimensionalidade num espaço de menor dimensão (neste caso, um plano 2D), garantindo que a nova projeção retenha a **máxima variância original** possível. A escolha do PCA em detrimento da simples seleção de duas variáveis originais justifica-se pelo fato de que cada Componente Principal (*PC*) gerado não é uma coluna isolada, mas sim uma combinação linear ortogonal de todas as cinco variáveis originais simultaneamente. Dessa forma, o algoritmo comprime a informação global sem gerar correlação entre os novos eixos.

Os eixos do gráfico de dispersão representam as direções de maior dispersão dos dados e podem ser interpretados analiticamente através do peso (*loadings*) que as variáveis originais exercem sobre eles:

- **Primeiro Componente Principal (PC_1 — Eixo Horizontal):** É o componente

que captura a maior percentagem da variância global dos dados. Neste estudo, o PC_1 funciona como o **Eixo de Escala e Popularidade**. Variáveis de volume como `estimated_owners`, `num_reviews_total` e `peak_ccu` exercem forte peso positivo neste vetor. Portanto, quanto mais à direita um jogo se posiciona no gráfico, maior é o seu impacto massivo de mercado e tração de comunidade (como observado no *Cluster 2*).

- **Segundo Componente Principal (PC_2 — Eixo Vertical):** Captura a maior parte da variância remanescente que não foi explicada pelo primeiro eixo, atuando de forma ortogonal (independente). Neste ecossistema, o PC_2 comporta-se como o **Eixo de Posicionamento Crítico e Monetização**, sendo fortemente influenciado pelas variáveis `price` e `pct_pos_total`. Ele serve para discriminar o modelo de negócio e a qualidade percebida: jogos situados na metade superior do gráfico possuem maior valor agregado financeiro ou taxas de aprovação mais unânimes, enquanto a metade inferior concentra títulos de baixo custo ou severamente rejeitados pelo público (como o *Cluster 1*).

4.2.6.2 Perfil dos Clusters




Figura 4 – Mapa de calor dos perfis dos *clusters*. As cores indicam a variação das médias em relação à média geral do mercado (Z-score).

A análise da tabela de centroides (médias de cada atributo) cruzada com os títulos alocados em cada grupo permitiu traçar com clareza o perfil de negócio de cada segmento. O algoritmo segmentou o ecossistema da Steam nas seguintes categorias lógicas:

- **Cluster 2 (Mega-Sucessos):** Composto por 1.584 títulos, este é o grupo da elite comercial. Destaca-se no extremo direito do espaço vetorial (alta pontuação em PC1), apresentando números incomparáveis: uma base instalada média de 3,5 milhões de proprietários e o maior pico de jogadores simultâneos (média de 5.128 CCU). A presença de gigantes da indústria contemporânea neste grupo — como *Elden Ring*, *Cyberpunk 2077*, *Baldur's Gate 3* e *Black Myth: Wukong* — atesta a sua natureza. Com uma elevada taxa de aprovação (86%), este grupo representa a intersecção perfeita entre orçamentos colossais, forte apelo comercial e aclamação crítica.
- **Cluster 0 (Títulos Premium e Categoria "AA"):** Um grupo de 1.184 jogos caracterizado por uma barreira de entrada financeira mais acentuada, ostentando o maior preço médio de todo o mercado avaliado (39,70 dólares). Embora não atinjam a escala viral do Cluster 2, estes jogos mantêm um modelo de negócio altamente rentável, com uma média sólida de 159 mil proprietários e picos de CCU expressivos (168,2). Representam, maioritariamente, estúdios de médio e grande porte que entregam experiências estruturadas e consistentes, refletidas numa aprovação global de 78,2%.
- **Cluster 4 (Sucessos Independentes / "Indie Hits"):** Englobando 4. 102 jogos, este *cluster* mapeia o ideal de sucesso para estúdios independentes. Comercializados a um preço médio acessível (9,97 dólares), estes títulos conseguiram furar a barreira do anonimato, garantindo uma excelente base de aproximadamente 337 mil utilizadores. A altíssima média de aprovação positiva (85,7%) combinada com um robusto volume de avaliações escritas (média de 2.591) indica um elevado nível de paixão e fidelização por parte da comunidade, configurando um excecional custo-benefício percebido.
- **Cluster 3 (Mercado Massivo de Jogos Comuns):** Sendo o maior agrupamento da análise (5.923 jogos), mapeia a base silenciosa da plataforma. É caracterizado por baixíssimo engajamento (média de apenas 7,4 CCU) e volumes residuais de donos (24 mil). Curiosamente, a sua taxa de aprovação geral é a mais alta (87%), sugerindo a presença massiva de *micro-indies* aclamados por um público-alvo minúsculo. Contudo, devido à sua densidade, o grupo atua também como "repositório" para relançamentos problemáticos de baixo volume (como a *STAR WARS™: Battlefront Classic Collection*) ou projetos abandonados com forte rejeição, estabilizando-se pela sua falta de impacto estatístico global.
- **Cluster 1 (Baixo Desempenho e Qualidade Questionável):** Com 2. 757 títulos alocados, este grupo evidencia jogos que enfrentaram severa rejeição de mercado. Apresenta a pior perceção de qualidade global, com uma positividade de apenas 60,9%. Apesar de terem um preço de prateleira atrativo (9,62 dólares) e até alcançarem as bibliotecas de alguns milhares de jogadores (média de 87 mil donos),

falham criticamente na retenção (pico de apenas 9,2 CCU). É o retrato de projetos que não conseguiram sustentar interesse após o lançamento, seja por deficiências técnicas ou conceituais.

A coerência entre a separação geométrica obtida pelo PCA e os perfis comerciais descritos pelos centroides confirma que o algoritmo *K-Means* ($k = 5$) extraiu com sucesso os padrões latentes de consumo, separando com clareza as dinâmicas de rentabilidade, adoção e aceitação crítica no catálogo da Steam.

4.3 Regras de associação

4.3.1 Objetivo da análise

Esta etapa do estudo consistiu na implementação de um modelo de Mineração de Regras de Associação (*Association Rule Mining*), utilizando o algoritmo *Apriori*. Tradicionalmente aplicado em análises de cesta de compras (*Market Basket Analysis*), esta técnica estatística não supervisionada foi adaptada para o ecossistema da Steam com dois objetivos:

1. **Mapear Sinergias de Design:** Identificar quais mecânicas, subgêneros e características visuais (*tags* e gêneros) coexistem de forma orgânica e interdependente no desenvolvimento de jogos.
2. **Descobrir Fórmulas de Sucesso Comercial (Abordagem Direcionada a Metas):** Descobrir quais combinações específicas de atributos de *gamedev* atuam como gatilhos ou antecedentes estatísticos para o alcance de marcos críticos de mercado (preço premium, aclamação do público, alta retenção e viralidade).

4.3.2 Dados Utilizados

Para a execução da Mineração de Regras de Associação, a análise baseou-se no conjunto de dados consolidado (`df_processed`). Diferentemente do algoritmo de agrupamento anterior, que operou sobre um espaço vetorial estritamente numérico, a descoberta de associações exige a intersecção entre o *design* do produto e o seu impacto de mercado. Por conseguinte, os dados selecionados foram divididos em duas categorias principais de variáveis:

- **Variáveis Descritivas de *Gamedev* (Textuais):** As colunas `tags` e `genres` foram extraídas para representar perfil de características do jogo. Na plataforma Steam, estas variáveis contêm listas de classificações atribuídas tanto pelos programadores

quanto pela comunidade, descrevendo mecânicas (ex: *Shooter*, *Puzzle*), estilos visuais (ex: *Pixel Graphics*, *Anime*) e subgêneros (ex: *Rogue-lite*, *Visual Novel*).

- **Métricas de Desempenho e Comercialização (Contínuas):** Foram selecionadas quatro variáveis numéricas para atuar como indicadores de sucesso de mercado:
 - **price:** Valor comercial do título, definindo o seu modelo de monetização.
 - **pct_pos_total:** Percentagem de avaliações positivas, servindo como *proxy* para a satisfação do consumidor.
 - **average_playtime_forever:** Tempo médio histórico de jogo, representando o poder de retenção do *software*.
 - **peak_ccu:** Pico máximo de jogadores simultâneos (*Concurrent Users*), capturando a capacidade de viralização e tração massiva.

4.3.3 Pré-processamento

Antes da aplicação dos algoritmos de mineração de regras de associação, o conjunto de dados original exigiu uma rigorosa etapa de preparação. Como os algoritmos baseados em padrões frequentes são altamente sensíveis à cardinalidade e ao ruído da base de dados, estabeleceu-se um procedimento de higienização textual, redução de dimensionalidade e definição de metas estatísticas.

Cálculo de Limites de Mercado

Para relacionar as características dos jogos com o seu sucesso comercial, os números contínuos foram transformados em categorias fechadas (metas). Em vez de se adotarem valores aleatórios, utilizou-se a própria base de dados para definir esses limites, através do cálculo dos quantis:

- **Preço e Aprovação:** Adotou-se o terceiro quartil (Q_3 ou percentil 75) como limite. Isso significa que apenas os 25% dos jogos mais caros (**price**) e com as melhores notas (**pct_pos_total**) receberam esses "selos" de sucesso.
- **Retenção (*Playtime*):** Para evitar que jogos comprados mas nunca iniciados enviassem os dados, primeiramente filtraram-se apenas os jogos com tempo de jogo maior que zero. Dentro desse grupo, aplicou-se novamente o corte do terceiro quartil (Q_3) para identificar os títulos que mais retêm os jogadores.
- **Viralidade (*Peak CCU*):** Como poucos jogos concentram quase todos os jogadores simultâneos do mercado, utilizou-se um limite bem mais rigoroso: o percentil 95 (P_{95}). Assim, destacaram-se apenas os verdadeiros fenômenos de massa.

Limpeza do Vocabulário

O perfil de cada jogo foi criado unindo as informações de texto fornecidas pela plataforma e pelos jogadores (colunas *tags* e *genres*). Para padronizar essas palavras, aplicaram-se Expressões Regulares (*Regex*) com o objetivo de realizar uma limpeza automática. Esse processo removeu sobras de formatação (como chaves, colchetes e aspas) e apagou os números que a API costuma colocar junto com as *tags*, deixando apenas os textos limpos.

Filtragem e Redução de Dados

A quantidade final de *tags* gerada era extensa demais. Para que o processamento computacional ocorresse num tempo razoável e para que os resultados fossem realmente úteis, aplicaram-se duas técnicas para reduzir essas informações:

1. **Remoção de Termos Genéricos:** Criou-se uma lista para excluir *tags* muito amplas ou óbvias (como "*indie*", "*singleplayer*", "*action*", "*2d*"). Caso essas palavras fossem mantidas, o modelo geraria regras lógicas, porém óbvias demais e sem nenhum valor prático para o negócio.
2. **Foco nas Tendências Principais (Top 60):** Após a limpeza dos textos, contabilizou-se a frequência de aparição de cada *tag*. A análise foi limitada apenas às 60 *tags* mais frequentes da base de dados. Cortar as *tags* mais raras impede que o algoritmo trave ao tentar calcular combinações infinitas e força o modelo a encontrar padrões apenas em nichos de mercado já consolidados.

4.3.4 Algoritmo Utilizado

Para a descoberta de padrões entre o design dos jogos e o seu sucesso de mercado, optou-se pela utilização do algoritmo *Apriori*. Trata-se de uma técnica clássica de mineração de dados, comumente aplicada em análises de "cesta de compras" (*Market Basket Analysis*). O seu objetivo principal é encontrar conjuntos de características que aparecem juntas com frequência e, a partir delas, criar regras lógicas de associação no formato "Se o jogo tem os itens A e B, então ele também gera o resultado C".

O processo de aplicação do algoritmo foi dividido nas seguintes etapas:

1. Estruturação das Transações (Cestos)

O algoritmo exige que os dados sejam organizados como transações de compra. Por isso, cada jogo foi tratado como um cesto individual. Dentro desse cesto, foram colocadas as *tags* e os gêneros que descrevem o jogo (limitados aos 60 mais relevantes da plataforma). Além disso, o código avaliou o desempenho de cada título e adicionou os "selos" de mercado

(como `$_PREMIUM`, `_ACLAMADO` ou `_HIT_VIRAL`) diretamente dentro do cesto, caso o jogo tivesse atingido essas metas.

2. Codificação Binária

Como o algoritmo não consegue interpretar palavras soltas, as listas de itens precisaram ser traduzidas para um formato numérico estruturado. Utilizou-se a ferramenta `TransactionEncoder` para transformar a coleção de cestos numa grande tabela (matriz binária). Nessa tabela, cada coluna representa um item possível (uma *tag* ou um selo), e cada linha representa um jogo. O cruzamento entre linha e coluna é preenchido de forma binária (Verdadeiro ou Falso), indicando apenas se aquele jogo possui ou não aquele item específico.

3. Mineração de Itens Frequentes

Com a tabela pronta, o algoritmo *Apriori* foi utilizado para varrer os dados e encontrar as combinações que mais se repetem. Para focar apenas no que é relevante para o mercado, estabeleceu-se um "suporte mínimo" de 1%. Isso significa que o modelo ignorou combinações raras e procurou apenas os conjuntos de características (compostos por até três itens no máximo) que estivessem presentes em, pelo menos, 1% de todos os jogos analisados.

4. Geração das Regras de Associação

A última etapa consistiu em transformar esses itens frequentes em regras de causa e consequência úteis para a pesquisa. A partir das combinações validadas pelo *Apriori*, utilizou-se a métrica de "confiança" com um limite mínimo de 20%. Ou seja, para que uma regra fosse aprovada e incluída no relatório final, o resultado previsto pela regra tinha que se confirmar em, no mínimo, 20% dos casos onde as características de design iniciais estivessem presentes.

4.3.5 Resultados

A execução do algoritmo organizou as regras em seis categorias principais de pesquisa de mercado. Os resultados destacam as combinações mais fortes entre o planejamento visual e mecânico dos jogos e o seu impacto comercial. A seguir, apresentam-se as principais descobertas de cada grupo:



Figura 5 – Resultados da Análise de Regras de Associação aplicadas ao mercado Steam.

1. Sinergias de Desenvolvimento (Mecânicas interdependentes)

O modelo identificou associações estruturais muito fortes na criação dos jogos. Notou-se uma ligação quase direta entre jogos de tiro (*Shooter*) e a visão em primeira pessoa, resultando na categoria FPS com mais de 91% de confiança. Outro padrão evidente foi a forte mistura entre jogos de corrida (*Racing*) e esportes (*Sports*). Além disso, características como "Anime" e jogos baseados em decisões (*Choices Matter*) mostraram ser a base principal para a categoria de romances visuais (*Visual Novels*).

Beneficiários: Esta informação é valiosa principalmente para estúdios independentes e novos desenvolvedores, pois fornece um guia claro sobre as convenções de gênero que os jogadores esperam, reduzindo o risco de erro na definição da identidade central de um projeto.

2. Poder de Precificação (Justificativa para preços Premium)

A análise revelou uma "fórmula" clara para os jogos que conseguem cobrar os preços mais altos do mercado (o quartil superior). A combinação de elementos como Terceira Pessoa (*Third Person*), História Rica (*Story Rich*), Mundo Aberto (*Open World*) e Ótima Trilha Sonora (*Great Soundtrack*) dominou esta categoria. Isso indica que o mercado aceita pagar valores *premium* por aventuras de grande escala focadas em narrativa e imersão.

Beneficiários: Estúdios de médio e grande porte (AA ou AAA) beneficiam mais desta análise, uma vez que estas produções possuem os recursos necessários para investir em mundos abertos e narrativas complexas, justificando estrategicamente o posicionamento de preço elevado.

3. Ecossistema Gratuito (*Free-to-Play*)

No modelo de jogos gratuitos, os padrões apontaram para títulos focados em grandes comunidades. O algoritmo destacou que jogos que combinam Multijogador Massivo (*Massively Multiplayer*), elementos de RPG e Combate entre Jogadores (*PvP*) têm as maiores chances (acima de 60%) de adotar o modelo gratuito. Essa estrutura serve para derrubar a barreira de entrada e atrair a maior quantidade possível de usuários.

Beneficiários: Empresas focadas em serviços como plataforma (*Games as a Service*) retiram maior vantagem, pois utilizam esta estrutura para maximizar a base de usuários e alimentar sistemas de microtransações, fundamentais para a viabilidade do modelo gratuito.

4. Receita da Aclamação (Alta satisfação dos jogadores)

O perfil dos jogos com as maiores taxas de avaliações positivas apresentou um padrão muito específico. O modelo apontou que títulos descritos como "Fofos" (*Cute*), "Relaxantes", focados em Quebra-cabeças (*Puzzle*) ou com Múltiplos Finais (*Multiple Endings*) dominam as maiores notas de aprovação. Isso demonstra que jogos acolhedores e nichos narrativos costumam satisfazer plenamente o seu público-alvo, sofrendo muito menos avaliações negativas do que jogos de ação competitivos.

Beneficiários: Desenvolvedores de jogos de nicho ou "confortáveis" (*cozy games*) são os maiores beneficiários, pois confirmam que, ao focarem na experiência do usuário e na redução de frustração, conseguem construir uma reputação sólida e alta fidelidade, mesmo sem orçamentos massivos.

5. Motores de Engajamento (Maior tempo de retenção)

Para prender a atenção e manter os usuários jogando por longos períodos, a presença da característica Mundo Aberto (*Open World*) provou ser o fator principal. Quando combinada com elementos de RPG, liberdade de criação (*Sandbox*) ou atmosferas ricas (*Atmospheric*), essa estrutura gerou os maiores tempos de jogo retidos na plataforma.

Beneficiários: Equipes de *design* de sistemas e retenção beneficiam desta visão, especialmente ao planearem conteúdos de longo prazo (expansões ou atualizações), garantindo que a base de jogadores se mantenha ativa através de sistemas de exploração e progressão contínua.

6. Potencial Viral (Picos de jogadores simultâneos)

Por fim, ao investigar quais mecânicas conseguem estourar os limites e gerar os maiores picos de jogadores simultâneos (o top 5% do mercado), o algoritmo encontrou um grande destaque absoluto: o modo Cooperativo Online (*Online Co-Op*). Isso reforça que a viralidade extrema e os grandes sucessos repentinos da plataforma são fortemente impulsionados por experiências sociais, onde os jogadores precisam convidar amigos para participarem da partida.

Beneficiários: Equipes de marketing e gestores de comunidade são o segmento que mais beneficia, ao perceberem que o desenvolvimento de funcionalidades cooperativas funciona como um motor de marketing orgânico, essencial para atingir picos de visibilidade na plataforma.

Conclusão

A análise realizada permitiu identificar padrões claros que governam o comportamento do mercado na Steam, revelando que o sucesso comercial não é fruto do acaso, mas sim da combinação estratégica de elementos de *design* com modelos de monetização adequados.

Principais Achados

Os resultados indicam que o mercado de jogos é altamente segmentado. Observou-se que a estrutura técnica — como a combinação de mecânicas de tiro com a visão em primeira pessoa ou de elementos de RPG com mundos abertos — atua como um pilar de confiança para o consumidor. Além disso, a precificação *premium* mostrou-se diretamente ligada a produções que priorizam a imersão narrativa e a qualidade audiovisual, enquanto o modelo *Free-to-Play* revelou-se a estratégia mais eficaz para títulos focados em experiências sociais e multijogador em grande escala.

Análise Crítica

Embora o algoritmo *Apriori* tenha sido eficiente para mapear as preferências dominantes, é importante ressaltar que a análise se baseou em tendências consolidadas. Isso significa que o modelo é excelente para identificar o que "funciona" dentro do *status quo* da indústria, mas pode deixar de capturar inovações disruptivas ou novos gêneros que ainda não possuem um volume de dados suficiente para serem considerados "frequentes". Além disso, a filtragem aplicada na etapa de pré-processamento, embora necessária para evitar a explosão combinatória, pode ter omitido nichos de mercado extremamente específicos que, embora menores, possuem comunidades de jogadores muito fiéis.

Relação com o Cenário Atual da Indústria

Os achados deste trabalho alinham-se com notícias e relatórios recentes sobre o setor de *gamedev*. A tendência observada em relação à viralidade impulsionada pelo modo cooperativo, por exemplo, reflete o comportamento de diversos sucessos recentes na plataforma, que dependem fortemente de mecânicas sociais e da propagação orgânica via comunidades e criadores de conteúdo. Da mesma forma, a valorização dos chamados *cozy games* ou jogos "acolhedores" reflete uma mudança de consumo identificada por veículos do setor, onde parte do público busca experiências de menor estresse e alta satisfação emocional. Em suma, o estudo valida que o sucesso no desenvolvimento de jogos atuais

depende de um alinhamento rigoroso entre a mecânica escolhida, o público-alvo pretendido e o modelo de negócio aplicado.

Referências

Artermiloff. *Steam Games Dataset (games_march2025_cleaned.csv)*. 2025. Disponível em: <<https://www.kaggle.com/datasets/artermiloff/steam-games-dataset>>. Acesso em: 26 maio 2026.

CARLESS, S. *GameDiscoverCo: Game Discovery Insights and Analysis*. 2024. Website público. Disponível livremente sem login. Acesso em: 26 maio 2026. Disponível em: <<https://gamediscover.co>>.

DemandSage. *Steam Statistics (2026) - Users, Market Share & Revenue*. 2026. Disponível em: <<https://www.demandsage.com/steam-statistics/>>. Acesso em: 26 maio 2026.

Fortune Business Insights. *Gaming Market Size, Industry Share, Growth & Forecast 2034*. 2025. Disponível em: <<https://www.fortunebusinessinsights.com/gaming-market-105730>>. Acesso em: 26 maio 2026.

LIN, D. et al. An empirical study of game reviews on the steam platform. *Empirical Software Engineering*, Springer, v. 24, n. 1, p. 170–207, 2019. Disponível em: <<https://doi.org/10.1007/s10664-018-9627-4>>.

MARCHAND, A.; HENNIG-THURAU, T. Value creation in the video game industry: Industry economics, consumer benefits, and research opportunities. *Journal of Interactive Marketing*, Elsevier, v. 27, n. 3, p. 141–157, 2013. Disponível em: <<https://doi.org/10.1016/j.intmar.2013.05.001>>.

Quantumrun Foresight. *PC Gaming Market Size Statistics And Demographics*. 2026. Disponível em: <<https://www.quantumrun.com/consulting/pc-gaming-market-size-statistics/>>. Acesso em: 26 maio 2026.

SIFA, R.; BAUCKHAGE, C.; DRACHEN, A. The playtime fringe: A large-scale analysis of player retention in steam. In: *Proceedings of the 2015 Annual Symposium on Computer-Human Interaction in Play*. [s.n.], 2015. p. 691–696. Disponível em: <<https://doi.org/10.1145/2793107.2793117>>.

Video Game Insights. *Steam Market Report 2025: Revenue and Release Statistics*. 2025. Disponível em: <<https://vginsights.com/insights/article/steam-market-report-2025>>. Acesso em: 26 maio 2026.

ZUKOWSKI, C. *How To Market A Game: Data-driven insights into Steam developer strategies*. 2025. Website público. Disponível livremente sem login. Acesso em: 26 maio 2026. Disponível em: <<https://howtomarketagame.com>>.

ZUO, C.; YIN, H. et al. Predicting the commercial success of pc games: A data-driven approach on steam. *Journal of Game Data Science*, 2021. Disponível em: <<https://scholar.google.com/>>.